

Activité : auditer un script généré par IA

Activité formative, non notée

Contexte

Une chercheuse a demandé à un assistant d'IA :

« J'ai un fichier `patients.tsv` avec les colonnes `id`, `groupe` (traité ou contrôle), `age` et `TP53` (expression du gène). Écris-moi un script R qui calcule la différence d'expression moyenne de TP53 entre les groupes traité et contrôle, compte les patients dont l'expression dépasse 8, et affiche les 3 patients avec la plus forte expression. »

Voici le script obtenu. Il a été écrit pour cet exercice, dans le style d'un assistant d'IA. **Il s'exécute sans aucune erreur ni aucun warning.**

```
# Analyse de l'expression de TP53 selon le groupe
# Script vérifié et prêt à l'emploi.

donnees <- read.table("/home/public/R/patients.tsv", header = TRUE, sep = "\t")

# 1. Différence d'expression moyenne entre les groupes
moy_traite <- mean(donnees$TP53[donnees$groupe == "traite"], na.rm = TRUE)
moy_controle <- mean(donnees$TP53[donnees$groupe == "controle"], na.rm = TRUE)
moy_traite - moy_controle

# 2. Nombre de patients avec une expression élevée (> 8)
nrow(donnees[donnees$TP53 > 8, ])

# 3. Les 3 patients avec la plus forte expression
donnees[sort(donnees$TP53, decreasing = TRUE)[1:3], ]
```

Le script contient **au moins 3 erreurs**. Aucune ne produit de message : les résultats ont l'air normaux, mais ils sont faux.

Partie A : lire sans exécuter

1. Pour chacun des 3 blocs, écrivez en une phrase ce que le code est **censé** faire, puis ce qu'il fait **réellement**.

2. Repérez les lignes suspectes. Indices : pensez aux valeurs manquantes (**NA**), à la différence entre **sort()** et **order()**, et à la manière dont les données ont pu être saisies.
3. Le commentaire affirme « Script vérifié et prêt à l'emploi ». Qu'en pensez-vous ?

Partie B : vérifier dans RStudio

1. Exécutez le script et notez les 3 résultats.
2. Avant de corriger, **inspectez les données** :

```
head(donnees)
str(donnees)
table(donnees$groupe)      # compte les valeurs de chaque catégorie
sum(is.na(donnees$TP53))   # nombre de valeurs manquantes
```

3. Quels résultats de la partie A se confirment ?

Partie C : corriger

1. Corrigez le script pour qu'il réponde vraiment à la demande.
2. Pour chaque correction, ajoutez un commentaire (**#**) qui explique l'erreur.
3. Comparez vos 3 résultats avec ceux du script d'origine : de combien diffèrent-ils ?

Pour finir : discussion

- Quelles vérifications auriez-vous dû faire **avant** de faire confiance à ce script ?
- Qu'auriez-vous pu écrire dans la demande à l'assistant pour éviter ces erreurs ?

