

Activité : auditer un script généré par IA

❗ Important

Corrigé. Réservé à la correction en classe : à déposer après la séance.

Activité formative, non notée

Contexte

Une chercheuse a demandé à un assistant d'IA :

« J'ai un fichier `patients.tsv` avec les colonnes `id`, `groupe` (traité ou contrôle), `age` et `TP53` (expression du gène). Écris-moi un script R qui calcule la différence d'expression moyenne de TP53 entre les groupes traité et contrôle, compte les patients dont l'expression dépasse 8, et affiche les 3 patients avec la plus forte expression. »

Voici le script obtenu. Il a été écrit pour cet exercice, dans le style d'un assistant d'IA. **Il s'exécute sans aucune erreur ni aucun warning.**

```
# Analyse de l'expression de TP53 selon le groupe
# Script vérifié et prêt à l'emploi.

donnees <- read.table("/home/public/R/patients.tsv", header = TRUE, sep = "\t")

# 1. Différence d'expression moyenne entre les groupes
moy_traite <- mean(donnees$TP53[donnees$groupe == "traite"], na.rm = TRUE)
moy_controle <- mean(donnees$TP53[donnees$groupe == "controle"], na.rm = TRUE)
moy_traite - moy_controle

# 2. Nombre de patients avec une expression élevée (> 8)
nrow(donnees[donnees$TP53 > 8, ])

# 3. Les 3 patients avec la plus forte expression
donnees[sort(donnees$TP53, decreasing = TRUE)[1:3], ]
```

Le script contient **au moins 3 erreurs**. Aucune ne produit de message : les résultats ont l'air normaux, mais ils sont faux.

Les données

```
donnees
#>      id  groupe age TP53
#> 1 P01   traite  34  9.7
#> 2 P02 controle  51  5.1
#> 3 P03   traite  47 11.6
#> 4 P04 Controle  62  4.8
#> 5 P05   traite  29  NA
#> 6 P06 controle  55  6.2
#> 7 P07   traite  41 10.9
#> 8 P08 Controle  58  3.9
#> 9 P09   traite  66  8.4
#> 10 P10 controle  38  5.6
#> 11 P11   traite  53  9.1
#> 12 P12 controle  45  7.3
table(donnees$groupe)
#>
#> controle Controle   traite
#>         4         2         6
sum(is.na(donnees$TP53))
#> [1] 1
```

Deux constats avant même de lire le script : le groupe contrôle est saisi de **deux façons** (`controle` et `Contrôle`), et une valeur de `TP53` est **manquante** (P05).

Erreur 1 : deux patients contrôles oubliés

```
donnees$TP53[donnees$groupe == "controle"]
#> [1] 5.1 6.2 5.6 7.3
```

La comparaison `== "controle"` ignore `"Contrôle"` (R distingue les majuscules) : la moyenne du groupe contrôle est calculée sur **4 patients au lieu de 6**. On uniformise d'abord la saisie :

```
donnees$groupe <- tolower(donnees$groupe)
table(donnees$groupe)
#>
#> controle   traite
#>         6         6
```

Erreur 2 : le patient sans valeur est compté

```
donnees$TP53 > 8
#> [1] TRUE FALSE TRUE FALSE NA FALSE TRUE FALSE TRUE FALSE TRUE FALSE
```

```
nrow(donnees[donnees$TP53 > 8, ])  
#> [1] 6
```

Pour P05, `NA > 8` vaut `NA` : la sélection ajoute une rangée `NA`, que `nrow()` compte. On obtient **6 au lieu de 5**.
Correction : compter les `TRUE` en ignorant les `NA`.

```
sum(donnees$TP53 > 8, na.rm = TRUE)  
#> [1] 5
```

Erreur 3 : `sort()` au lieu de `order()`

```
sort(donnees$TP53, decreasing = TRUE)[1:3]  
#> [1] 11.6 10.9 9.7
```

`sort()` renvoie des **valeurs** (11.6, 10.9, 9.7), que R utilise comme **numéros de rangées** (tronqués à 11, 10, 9). Le script affiche donc les patients P11, P10 et P09, dont **un patient contrôle** avec une expression de 5.6, sans aucun message. `order()` renvoie les positions des valeurs triées :

```
head(donnees[order(donnees$TP53, decreasing = TRUE), ], 3)  
#>   id groupe age TP53  
#> 3 P03 traite  47 11.6  
#> 7 P07 traite  41 10.9  
#> 1 P01 traite  34  9.7
```

Le commentaire « Script vérifié »

Un assistant d'IA ne vérifie pas les résultats sur *vos* données : il produit un texte plausible. Ce commentaire n'engage que celui qui le laisse dans le script. C'est la personne qui signe l'analyse qui en est responsable.

Script corrigé

```
# Analyse de l'expression de TP53 selon le groupe  
  
donnees <- read.table("data/patients.tsv", header = TRUE, sep = "\t")  
  
# Vérifications : catégories et valeurs manquantes  
table(donnees$groupe)  
#>  
#> controle Controle  traite  
#>         4         2         6  
sum(is.na(donnees$TP53))  
#> [1] 1
```

```
# Correction 1 : le groupe contrôle est saisi "controle" et "Contrôle"
donnees$groupe <- tolower(donnees$groupe)

# 1. Différence d'expression moyenne entre les groupes
moy_traite <- mean(donnees$TP53[donnees$groupe == "traite"], na.rm = TRUE)
moy_controle <- mean(donnees$TP53[donnees$groupe == "controle"], na.rm = TRUE)
moy_traite - moy_controle
#> [1] 4.456667

# 2. Nombre de patients avec une expression > 8
# Correction 2 : NA > 8 donne NA ; on compte les TRUE en ignorant les NA
sum(donnees$TP53 > 8, na.rm = TRUE)
#> [1] 5

# 3. Les 3 patients avec la plus forte expression
# Correction 3 : order() (positions) et non sort() (valeurs)
head(donnees[order(donnees$TP53, decreasing = TRUE), ], 3)
#>   id groupe age TP53
#> 3 P03 traite  47 11.6
#> 7 P07 traite  41 10.9
#> 1 P01 traite  34  9.7
```

Comparaison des résultats

Résultat	Script d'origine	Script corrigé
Différence de moyennes	3.89	4.46
Patients avec TP53 > 8	6	5
Top 3	P11, P10 (contrôle), P09	P03, P07, P01

Les trois résultats sont faux, et rien ne l'indiquait à l'exécution.

Cinq vérifications systématiques

À faire avant de faire confiance à un script, qu'il ait été écrit par vous ou généré par un outil :

- Les catégories** : `table()` sur chaque colonne de texte (fautes de saisie, majuscules, espaces).
- Les valeurs manquantes** : `sum(is.na())` sur les colonnes utilisées dans les calculs.
- Les dimensions** : `nrow()` avant et après chaque sélection. Le nombre obtenu est-il plausible ?
- Quelques lignes vérifiées à la main** : le patient affiché en tête a-t-il vraiment la plus forte valeur ?
- Un calcul indépendant** : retrouver un résultat par une autre méthode (`sum()` contre `nrow()` , `max()` contre le tri).

Et dans la demande à l'assistant : préciser qu'il y a des NA, que la saisie des catégories n'est pas homogène, et lui demander d'inclure ces vérifications dans le script.

