

TP1 : les verbes de dplyr

Avant de débiter

Connectez-vous au serveur RStudio du cours : <https://bif-rstudio.compbio.ulaval.ca>

Ouvrez un **nouveau script** (*File > New File > R Script*) qui contiendra toutes les étapes de votre travail, et commencez par charger le *tidyverse* :

```
library(tidyverse)
```

Si R répond `there is no package called 'tidyverse'`, le package n'est pas installé dans votre compte : `install.packages("tidyverse")` (une seule fois).

Les données

Le fichier `/home/public/tidyverse/grades.tsv` contient les notes (anonymisées) de 79 étudiants d'un cours, sur trois années :

Colonne	Contenu
<code>ID_etu</code>	identifiant de l'étudiant
<code>D1</code> à <code>D4</code>	notes des 4 devoirs (sur 100)
<code>E1</code> , <code>E2</code>	notes des 2 examens (sur 100)
<code>Annee</code>	année du cours (2018, 2019 ou 2020)
<code>Cohorte</code>	<code>Cycle 1</code> ou <code>Cycle 2 et 3</code>

Rappel : les verbes

Verbe	Rôle	Exemple
<code>select()</code>	garder des colonnes	<code>select(df, id, E1)</code>

Verbe	Rôle	Exemple
<code>filter()</code>	garder des lignes	<code>filter(df, E1 > 80)</code>
<code>mutate()</code>	créer ou modifier une colonne	<code>mutate(df, total = D1 + D2)</code>
<code>arrange()</code>	trier les lignes	<code>arrange(df, desc(E1))</code>
<code>count()</code>	compter les lignes par valeur	<code>count(df, Annee)</code>

Chaque verbe prend un tableau et renvoie un tableau : on les enchaîne avec le *pipe* `|>` (« puis »).

À votre tour

0. Importez le fichier avec `read_tsv()` et assignez-le à la variable `grades`. Lisez le message affiché : combien de lignes et de colonnes ? Quel type a été deviné pour chaque colonne ?
1. Affichez uniquement les colonnes `ID_etu`, `E1` et `E2`.
2. Gardez uniquement les étudiants de l'année 2019. Combien sont-ils ?
3. Gardez les étudiants de l'année 2019 **et** de la cohorte `Cycle 1`. Combien sont-ils ?
4. Ajoutez une colonne `moyenne_exam` qui contient la moyenne des deux examens : $(E1 + E2) / 2$.
5. Combien d'étudiants ont obtenu plus de 90 à l'examen `E2` ?
6. Affichez les 5 meilleures notes à l'examen `E2` (colonnes `ID_etu` et `E2` seulement), de la meilleure à la moins bonne.
7. Combien y a-t-il d'étudiants dans chaque cohorte ? Et dans chaque année ?

Et si... ?

Pour chaque question, **prédisez d'abord la réponse sans exécuter**, puis vérifiez dans R. Si le résultat vous surprend, cherchez pourquoi.

1. Et si on voulait les étudiants de 2019 **ou** 2020 et qu'on écrivait `filter(grades, Annee == 2019 | 2020)` : combien de lignes obtiendrait-on ? Pourquoi ? Comment l'écrire correctement ?
2. Et si on écrivait `filter(grades, Cohorte == c("Cycle 1", "Cycle 2 et 3"))` pour garder les deux cohortes : obtient-on les 79 étudiants ? Lisez le message.
3. Combien d'étudiants ont moins de 70 au devoir `D2` ? Combien ont 70 ou plus ? La somme fait-elle 79 ? Qui manque, et pourquoi ?
4. Et si on exécutait `grades |> mutate(moyenne_exam = (E1 + E2) / 2)`, puis `grades$moyenne_exam` : que renvoie R ? Pourquoi ?
5. Et si on triait par `D2` avec `arrange(D2)`, puis avec `arrange(desc(D2))` : où se trouve l'étudiant sans note de `D2` dans chacun des cas ?

