

TP3 : les jointures

Rappel

```
left_join(x, y, by = "cle")           # toutes les lignes de x, complétées par y
left_join(x, y, by = join_by(cle_x == cle_y)) # si la clé ne porte pas le même nom
inner_join(x, y, by = "cle")          # seulement les lignes présentes dans les
anti_join(x, y, by = "cle")           # les lignes de x sans correspondance dans y
```

Après **chaque** jointure : comparer le nombre de lignes avant et après, chercher les clés en double (`count(cle)`)
`> filter(n > 1)`) et les clés sans correspondance (`anti_join()`).

Partie A : les notes et le sexe

Le fichier `/home/public/tidyverse/grades_sex.tsv` contient deux colonnes : `ID_etu` et `Sex`.

1. Importez-le dans la variable `sexe`, puis joignez-le à `grades` (TP1) pour ajouter le sexe de chaque étudiant.
Le nombre de lignes a-t-il changé ? Tous les étudiants ont-ils trouvé une correspondance ?
2. Calculez la moyenne de l'examen `E2` et le nombre d'étudiants par année et par sexe.

Partie B : les vols au départ de New York

Le package `nycflights13` contient tous les vols au départ des 3 aéroports de New York en 2013, répartis dans plusieurs tableaux reliés par des clés :

```
library(nycflights13)
flights  # un vol par ligne : carrier (code de la compagnie), dest (code de l'aéroport)
airlines  # carrier -> name (nom complet de la compagnie)
airports  # faa (code de l'aéroport) -> name, lat, lon...
```

3. Combien de compagnies aériennes différentes y a-t-il dans `airlines` ?
4. En joignant `flights` et `airlines`, quelles sont les 3 compagnies qui ont le plus grand **retard moyen** à l'arrivée ? Affichez leur nom complet, pas leur code.
5. Joignez `flights` et `airports` (la colonne `dest` de `flights` correspond à la colonne `faa` de `airports`).
Pour chaque aéroport de destination (`name`), calculez la distance moyenne depuis New York, le retard moyen à l'arrivée et le nombre de vols. Triez du plus grand au plus petit retard moyen.

6. Vers combien de destinations différentes peut-on voler depuis New York ? Avec `anti_join()`, trouvez les codes `dest` de `flights` qui n'existent pas dans `airports`. Combien de vols sont concernés ?

Et si... ?

Pour chaque question, **prédisez d'abord la réponse sans exécuter**, puis vérifiez dans R. Si le résultat vous surprend, cherchez pourquoi.

1. Et si on utilisait `inner_join()` au lieu de `left_join()` à la question 5 : combien de vols disparaîtraient ? Lesquels ?
2. Et si le tableau `sexe` contenait un étudiant **en double** (`sexe_double <- bind_rows(sexe, sexe[1, ])`) : combien de lignes aurait la jointure avec `grades` ? Obtient-on un message ? Qu'est-ce que cela change aux moyennes de la question 2 ?
3. Et si les identifiants étaient écrits en minuscules dans `sexe` (`etu_1` au lieu de `Etu_1`) : que contiendrait la colonne `Sex` après la jointure ? Obtient-on une erreur ?
4. Et si on joignait `flights` et `airports` sans préciser `by` : `left_join(flights, airports)` ? Et `left_join(flights, airlines)` ?

