

Activité : auditer un script ggplot2 généré par IA

Activité formative, non notée

Contexte

L'équipe pédagogique veut comparer les deux cohortes d'étudiants du cours (Cycle 1 et Cycle 2 et 3). Elle dispose du fichier `grades.tsv` du module 6 : une ligne par étudiant, `ID_etu`, les notes sur 100 de six évaluations dans l'ordre du trimestre (`D1`, `D2`, `E1`, `D3`, `D4`, `E2`), `Annee` et `Cohorte`.

Elle a demandé à un assistant d'IA :

« À partir de `grades.tsv`, compare les deux cohortes : (1) la distribution des notes de chaque évaluation, dans l'ordre du trimestre (`D1`, `D2`, `E1`, `D3`, `D4`, `E2`) ; (2) un barplot de la note moyenne de chaque cohorte. Les notes sont sur 100. »

Voici le script obtenu. Il a été écrit pour cet exercice, dans le style d'un assistant d'IA. **Il s'exécute sans aucune erreur.**

```
library(tidyverse)
# Script vérifié : s'exécute sans erreur.
notes <- read_tsv("/home/public/tidyverse/grades.tsv")

notes_long <- notes |>
  pivot_longer(D1:E2, names_to = "Type", values_to = "Note")

# 1. Distribution des notes par évaluation et par cohorte
ggplot(notes_long, aes(x = Type, y = Note, fill = Cohorte)) +
  geom_boxplot() +
  scale_y_continuous(limits = c(50, 100)) + # les notes sont sur 100
  theme_bw()

# 2. Note moyenne par cohorte
ggplot(notes_long, aes(x = Cohorte, y = Note, fill = "steelblue")) +
  geom_col() +
  labs(y = "Note moyenne")
```

Le script contient **au moins 3 erreurs**. Aucune ne produit d'erreur : les graphiques ont l'air normaux, mais ils sont faux ou ne répondent pas à la demande. Attention, certaines lignes sont **correctes** : ne corrigez que ce qui doit

l'être.

Partie A : lire sans exécuter

1. Pour chaque bloc, écrivez en une phrase ce que le code est **censé** faire, puis ce qu'il fait **réellement**.
2. Relisez la **demande** : dans quel ordre les évaluations apparaîtront-elles sur le graphique 1 ?
3. Que fait `scale_y_continuous(limits = c(50, 100))` d'une note de 35 ? Le commentaire qui l'accompagne est-il juste ?
4. Dans le graphique 2, combien de lignes de `notes_long` tombent dans chaque barre ? Que fait `geom_col()` de ces lignes ? Quel ordre de grandeur attendez-vous sur l'axe y ?
5. De quelle couleur seront les barres du graphique 2 ? Que dira la légende ?
6. Le commentaire affirme « Script vérifié ». Qu'en pensez-vous ?

Partie B : vérifier dans RStudio

1. Exécutez le script. Lisez **tous** les messages, y compris les *warnings*, et regardez les **axes** et les **légendes**.
2. Avant de corriger, **calculez** ce que les graphiques devraient montrer :

```
notes_long |> summarise(moyenne = mean(Note, na.rm = TRUE), n = n(), .by = Cohorte)
notes_long |> summarise(sous_50 = sum(Note < 50, na.rm = TRUE), manquantes = sum(is.na(Note)))
notes_long |> summarise(mediane = median(Note, na.rm = TRUE), .by = c(Type, Cohorte))
```

3. Quels soupçons de la partie A se confirment ?

Partie C : corriger

1. Corrigez le script pour qu'il réponde vraiment à la demande.
2. Pour chaque correction, ajoutez un commentaire (`#`) qui explique l'erreur.
3. Pour le graphique 2, un barplot est-il vraiment le meilleur choix ? Proposez une alternative.

Pour finir : discussion

- Lesquelles de ces erreurs se voyaient **sur le graphique**, et lesquelles seulement dans les messages ou en refaisant les calculs ?
 - Le commentaire `# les notes sont sur 100` donnait-il confiance ? Avait-il raison ?
 - Qu'auriez-vous pu écrire dans la demande à l'assistant pour éviter ces erreurs ?
-