

Activité : auditer un script ggplot2 généré par IA

❗ Important

Corrigé. Réservé à la correction en classe : à déposer après la séance.

Activité formative, non notée

Contexte

L'équipe pédagogique veut comparer les deux cohortes d'étudiants du cours (Cycle 1 et Cycle 2 et 3). Elle dispose du fichier `grades.tsv` du module 6 : une ligne par étudiant, `ID_etu`, les notes sur 100 de six évaluations dans l'ordre du trimestre (`D1`, `D2`, `E1`, `D3`, `D4`, `E2`), `Annee` et `Cohorte`.

Elle a demandé à un assistant d'IA :

« À partir de `grades.tsv`, compare les deux cohortes : (1) la distribution des notes de chaque évaluation, dans l'ordre du trimestre (`D1`, `D2`, `E1`, `D3`, `D4`, `E2`) ; (2) un barplot de la note moyenne de chaque cohorte. Les notes sont sur 100. »

Voici le script obtenu. Il a été écrit pour cet exercice, dans le style d'un assistant d'IA. **Il s'exécute sans aucune erreur.**

```
library(tidyverse)
# Script vérifié : s'exécute sans erreur.
notes <- read_tsv("/home/public/tidyverse/grades.tsv")

notes_long <- notes |>
  pivot_longer(D1:E2, names_to = "Type", values_to = "Note")

# 1. Distribution des notes par évaluation et par cohorte
ggplot(notes_long, aes(x = Type, y = Note, fill = Cohorte)) +
  geom_boxplot() +
  scale_y_continuous(limits = c(50, 100)) + # les notes sont sur 100
  theme_bw()


# 2. Note moyenne par cohorte
ggplot(notes_long, aes(x = Cohorte, y = Note, fill = "steelblue")) +
```

```
geom_col() +  
labs(y = "Note moyenne")
```


Le script contient **au moins 3 erreurs**. Aucune ne produit d'erreur : les graphiques ont l'air normaux, mais ils sont faux ou ne répondent pas à la demande. Attention, certaines lignes sont **correctes** : ne corrigez que ce qui doit l'être.

Les graphiques du script d'origine

```
ggplot(notes_long, aes(x = Type, y = Note, fill = Cohorte)) +  
  geom_boxplot() +  
  scale_y_continuous(limits = c(50, 100)) +  
  theme_bw()  
#> Warning: Removed 22 rows containing non-finite outside the scale range  
#> (`stat_boxplot()`).
```



```
ggplot(notes_long, aes(x = Cohorte, y = Note, fill = "steelblue")) +  
  geom_col() +  
  labs(y = "Note moyenne")  
#> Warning: Removed 1 row containing missing values or values outside the scale range  
#> (`geom_col()`).
```



Trois indices étaient visibles sans rien calculer : le *warning* **Removed 22 rows**, l'axe y du graphique 2 (des **milliers**, pour des notes sur 100), et la légende « steelblue ».

Erreur 1 : **limits** retire des notes

```
notes_long |> summarise(sous_50 = sum(Note < 50, na.rm = TRUE), manquantes = sum(is.na(Note)))
#> # A tibble: 1 × 2
#>   sous_50 manquantes
#>   <int>     <int>
#> 1     21         1

notes_long |>
  summarise(mediane = median(Note, na.rm = TRUE),
            mediane_sup50 = median(Note[Note >= 50], na.rm = TRUE), .by = Type)
#> # A tibble: 6 × 3
#>   Type   mediane mediane_sup50
#>   <chr>   <dbl>       <dbl>
#> 1 D1     93.3         93.3
#> 2 D2     90          90
#> 3 E1     75.6         75.6
#> 4 D3    100         100
#> 5 D4     94.1         95
#> 6 E2     82.9         85.4
```

limits dans une échelle ne zoome pas : il **supprime** les valeurs hors limites **avant** le calcul des boxplots. Les 21 notes sous 50 (les échecs !) disparaissent ; médianes, quartiles et moustaches sont calculés sans elles. Pour **E2**, la médiane passe de 82.86 à 85.39. Seul le *warning* (**Removed 22 rows** : 21 notes sous 50 et 1 **NA**) le signale.

Le commentaire **# les notes sont sur 100** est juste... et hors sujet : il justifie la borne haute, mais la borne **basse** à 50 n'a aucune raison d'être. Si on veut fixer l'axe de 0 à 100, **limits = c(0, 100)** ne retire rien ; pour zoomer, **coord_cartesian(ylim =)**.

Erreur 2 : les évaluations ne sont pas dans l'ordre du trimestre

`Type` est du texte : `ggplot2` le trie par ordre **alphabétique**, D1, D2, D3, D4, E1, E2. La demande précisait l'ordre du trimestre (D1, D2, **E1**, D3, D4, E2). Les deux examens se retrouvent côte à côte à la fin. On fixe l'ordre avec un facteur :

```
mutate(Type = fct_inorder(Type)) # ou factor(Type, levels = c("D1", "D2", "E1", "D3", 'E2'))
```

Erreur 3 : le barplot montre des sommes, pas des moyennes

```
notes_long |>
  summarise(somme = sum(Note, na.rm = TRUE), moyenne = mean(Note, na.rm = TRUE), n = n(),
#> # A tibble: 2 × 4
#>   Cohorte      somme moyenne     n
#>   <chr>      <dbl>   <dbl> <int>
#> 1 Cycle 1    19570.    79.9   246
#> 2 Cycle 2 et 3 20376.    89.4   228
```

Chaque cohorte compte plus de 200 lignes dans `notes_long`. `geom_col()` **empile** toutes les lignes qui ont le même `x` : chaque barre est la **somme** des notes (~20 000), pas leur moyenne, malgré le titre de l'axe. Pire, la somme dépend de l'**effectif** : l'écart entre cohortes paraît faible (4 %), alors que la différence de moyennes est de presque 10 points. Il faut calculer la moyenne d'abord, avec `summarise()`, puis `geom_col()` ; ou utiliser `stat_summary(fun = mean, geom = "col")`.

Erreur 4 : une couleur fixe placée dans `aes()`

Dans `aes()`, `"steelblue"` n'est pas une couleur mais **une donnée** (une colonne constante) : les barres prennent la première couleur de la palette (rouge saumon), et une légende inutile annonce « steelblue ». Une couleur fixe se met **hors** de `aes()` : `geom_col(fill = "steelblue")`.

Ce qui était correct

- `pivot_longer(D1:E2, names_to = "Type", values_to = "Note")` : le passage au format long est juste et nécessaire.
- `aes(x = Type, y = Note, fill = Cohorte) + geom_boxplot()` : le bon graphique pour comparer des distributions.
- `theme_bw()` : un choix d'apparence, sans effet sur les données.

Le commentaire « Script vérifié »


« S'exécute sans erreur » est vrai, et ne prouve rien : aucune des quatre erreurs n'en produit. Deux se voyaient pourtant en **lisant le graphique** (un axe en milliers pour des notes sur 100, une légende « steelblue »), une seulement en **lisant le warning** (les notes retirées), et une en **relisant la demande** (l'ordre). Un assistant d'IA ne regarde pas le graphique qu'il produit : c'est à la personne qui le présente de le lire.

Script corrigé

```
library(tidyverse)

notes_long <- notes |>
  pivot_longer(D1:E2, names_to = "Type", values_to = "Note") |>
  # Correction 2 : l'ordre du trimestre (sinon alphabétique : D1, D2, D3, D4, E1, E2)
  mutate(Type = fct_inorder(Type))


# 1. Distribution des notes par évaluation et par cohorte
ggplot(notes_long, aes(x = Type, y = Note, fill = Cohorte)) +
  geom_boxplot() +
  # Correction 1 : limits retirait les notes < 50 avant le calcul ; on fixe l'axe sans rien
  coord_cartesian(ylim = c(0, 100)) +
  theme_bw()
#> Warning: Removed 1 row containing non-finite outside the scale range
#> (`stat_boxplot()`).
```



```
# 2. Note moyenne par cohorte
moyennes <- notes_long |>
  # Correction 3 : calculer la moyenne d'abord (geom_col() additionnait les ~240 notes de
  summarise(moyenne = mean(Note, na.rm = TRUE), .by = Cohorte)

ggplot(moyennes, aes(x = Cohorte, y = moyenne)) +
```

```
# Correction 4 : couleur fixe hors de aes() (dans aes(), "steelblue" était une donnée)
geom_col(fill = "steelblue", width = 0.5) +
labs(y = "Note moyenne (sur 100)")
```



Mieux qu'un barplot

Le barplot de deux moyennes cache tout ce qui intéresse l'équipe : la dispersion, les échecs, les effectifs. Les points de chaque étudiant, avec la moyenne, en disent beaucoup plus :

```
moyennes_etu <- notes_long |>
  summarise(moyenne = mean(Note, na.rm = TRUE), .by = c(ID_etu, Cohorte))

ggplot(moyennes_etu, aes(x = Cohorte, y = moyenne)) +
  geom_jitter(width = 0.15, alpha = 0.6) +
  stat_summary(fun = mean, geom = "crossbar", width = 0.4, color = "red") +
  labs(y = "Moyenne de l'étudiant (sur 100)")
```

