

Exercice formatif : visualisation avec R

Répondez **sans exécuter de code**. Le but est de vérifier ce que vous avez compris, pas d'avoir tout juste : on corrige ensemble juste après.

Les questions 1 à 5 utilisent ce tableau *souris* : l'expression d'un gène chez 6 souris.

id	lignee	semaine	expression
M1	WT	1	5.1
M2	WT	2	5.8
M3	WT	3	6.4
M4	KO	1	8.2
M5	KO	2	9.0
M6	KO	3	4.3

1. Lire du code

Décrivez le graphique produit (axes, forme, couleurs, légende) :

```
ggplot(souris, aes(x = lignee, y = expression, color = lignee)) +  
  geom_point(size = 3) +  
  stat_summary(fun = mean, geom = "point", shape = 4, size = 6)
```

2. Mapping ou setting

On veut tous les points en rouge. Qu'obtient-on avec (a) `geom_point(aes(color = "red"))` ? (b) `geom_point(color = "red")` ? (c) `geom_point(color = lignee)` ?

3. `geom_bar()` ou `geom_col()` ?

(a) Que montre `ggplot(souris, aes(lignee)) + geom_bar()` ? (b) Et `ggplot(souris, aes(lignee, expression)) + geom_col()` ? Hauteur de chaque barre ? (c) Ce second graphique s'intitule « Expression moyenne par lignée ». Est-ce juste ?

4. Zoomer

On ajoute `+ ylim(5, 10)` à un boxplot de l'expression par lignée. (a) Que devient la souris M6 ? (b) La médiane affichée pour KO est-elle juste ? (c) Que fallait-il écrire ?

5. Des lignes

On veut l'évolution de l'expression au fil des semaines, une courbe par lignée. (a) Qu'est-ce qui ne va pas avec `ggplot(souris, aes(semaine, expression)) + geom_line()` ? (b) Corrigez.

6. Préparer les données

Le tableau `mesures` a une colonne `gene` et une colonne par échantillon : `ctrl_1`, `ctrl_2`, `trt_1`, `trt_2`. On veut un boxplot de l'expression par échantillon. (a) Pourquoi ne peut-on pas l'écrire directement ? (b) Quelle commande faut-il d'abord ? Écrivez-la. (c) Combien de lignes aura le résultat pour 1000 gènes ?

7. Lire un volcano plot

Sur un volcano plot ($\log_2\text{FoldChange}$ en x, $-\log_{10}(\text{p}adj)$ en y), le gène A est en (3, 1), le gène B en (-0.5, 25), le gène C en (-2, 8). (a) Lequel change le plus ? Lequel est le plus significatif ? (b) Lesquels passent les seuils $|\log_2\text{FC}| > 1$ et $\text{p}adj < 0.05$? (c) Pourquoi les gènes à $\text{p}adj$ manquante n'apparaissent-ils pas ?