

Exercice formatif : visualisation avec R — corrigé

Chaque réponse est suivie de la notion à revoir si elle a été manquée.

Les questions 1 à 5 utilisent ce tableau souris : l'expression d'un gène chez 6 souris.

id	lignee	semaine	expression
M1	WT	1	5.1
M2	WT	2	5.8
M3	WT	3	6.4
M4	KO	1	8.2
M5	KO	2	9.0
M6	KO	3	4.3

1. Lire du code

Décrivez le graphique produit (axes, forme, couleurs, légende) :

```
ggplot(souris, aes(x = lignee, y = expression, color = lignee)) +
  geom_point(size = 3) +
  stat_summary(fun = mean, geom = "point", shape = 4, size = 6)
```

En x, deux catégories (KO puis WT, ordre alphabétique) ; en y, l'expression. Trois points par lignée, une couleur par lignée (légende lignee), et une croix de la même couleur à la **moyenne** de chaque lignée (KO : 7.17 ; WT : 5.77). À revoir : la grammaire (data, aes, geom), stat_summary().

2. Mapping ou setting

On veut tous les points en rouge. Qu'obtient-on avec (a) `geom_point(aes(color = "red"))` ? (b) `geom_point(color = "red")` ? (c) `geom_point(color = lignee)` ?

(a) Des points **rouge saumon** (la première couleur de la palette) et une légende « red » : dans `aes()`, "red" est une donnée. (b) Des points rouges, sans légende : c'est la bonne réponse. (c) Une erreur, object 'lignee' not found : hors de `aes()`, R cherche une variable, pas une colonne. À revoir : mapping ou setting.

3. geom_bar() ou geom_col() ?

(a) Que montre `ggplot(souris, aes(lignee)) + geom_bar()` ? (b) Et `ggplot(souris, aes(lignee, expression)) + geom_col()` ? Hauteur de chaque barre ? (c) Ce second graphique s'intitule « Expression moyenne par lignée ». Est-ce juste ?

(a) Deux barres de hauteur 3 : `geom_bar()` compte les lignes. (b) Deux barres empilées : KO = 8.2 + 9.0 + 4.3 = **21.5**, WT = 5.1 + 5.8 + 6.4 = **17.3**, les **sommes**. (c) Non : le titre annonce des moyennes, le graphique montre des sommes, sans aucun message. Il faut `summarise(moyenne = mean(expression), .by = lignee)` avant `geom_col()`, ou mieux, montrer les 3 points. À revoir : `geom_bar()` compte, `geom_col()` empile.

4. Zoomer

On ajoute `ylim(5, 10)` à un boxplot de l'expression par lignée. (a) Que devient la souris M6 ? (b) La médiane affichée pour KO est-elle juste ? (c) Que fallait-il écrire ?

- (a) Son expression (4.3) est hors limites : elle est **retirée des données**, avec un simple *warning* `Removed 1 row.` (b) Non : la médiane KO devient celle de 8.2 et 9.0, soit 8.6, au lieu de **8.2** avec les trois souris. (c) `coord_cartesian(ylim = c(5, 10))` : zoom sans retirer de données. À revoir : *limits* et *coord_cartesian()*.

5. Des lignes

On veut l'évolution de l'expression au fil des semaines, une courbe par lignée. (a) Qu'est-ce qui ne va pas avec `ggplot(souris, aes(semaine, expression)) + geom_line()` ? (b) Corrigez.

- (a) Une **seule** ligne relie les 6 points dans l'ordre des semaines : elle zigzague entre WT et KO (5.1, 8.2, 5.8, 9.0...). Aucun message. (b) `aes(semaine, expression, color = lignee)` (ou `group = lignee`) : une ligne par lignée. À revoir : *aesthetic group*.

6. Préparer les données

Le tableau `mesures` a une colonne `gene` et une colonne par échantillon : `ctrl_1`, `ctrl_2`, `trt_1`, `trt_2`. On veut un boxplot de l'expression par échantillon. (a) Pourquoi ne peut-on pas l'écrire directement ? (b) Quelle commande faut-il d'abord ? Écrivez-la. (c) Combien de lignes aura le résultat pour 1000 gènes ?

- (a) L'échantillon est **dans les noms de colonnes** : aucune colonne ne peut aller en x. (b) `mesures |> pivot_longer(-gene, names_to = "echantillon", values_to = "expression")`, puis `ggplot(aes(echantillon, expression)) + geom_boxplot()`. (c) $1000 \times 4 = 4000$ lignes. À revoir : *le format long*.

7. Lire un volcano plot

Sur un volcano plot ($\log_2\text{FoldChange}$ en x, $-\log_{10}(\text{padj})$ en y), le gène A est en (3, 1), le gène B en (-0.5, 25), le gène C en (-2, 8). (a) Lequel change le plus ? Lequel est le plus significatif ? (b) Lesquels passent les seuils $|\log_2\text{FC}| > 1$ et $\text{padj} < 0.05$? (c) Pourquoi les gènes à padj manquante n'apparaissent-ils pas ?

- (a) A change le plus ($2^3 = 8$ fois), B est le plus significatif ($\text{padj} = 10^{-25}$) mais change peu (un facteur $2^{0.5} \approx 1.4$). (b) Seuil $\text{padj} < 0.05 \iff y > 1.3$. A : $y = 1$, $\text{padj} = 0.1$, **non significatif** malgré le grand changement. B : significatif mais $|\log_2\text{FC}| < 1$. Seul **C** passe les deux seuils (4 fois moins exprimé, $\text{padj} = 10^{-8}$). (c) $-\log_{10}(\text{NA})$ vaut NA : `ggplot2` retire ces points avec un *warning*. Ce sont des gènes **non testés**, pas des gènes « non significatifs ». À revoir : *lire un volcano plot*.