


Solutionnaire du TP2

```
library(tidyverse)
bebes <- read_csv("/home/public/tidyverse/babynames.csv")
notes <- read_tsv("/home/public/tidyverse/grades.tsv")
sexes <- read_tsv("/home/public/tidyverse/grades_sex.tsv")
```

À votre tour

1. Naissances par année

```
naissances <- bebes |> summarise(n = sum(n), .by = year)
ggplot(naissances, aes(year, n)) +
  geom_line() +
  labs(x = "Année", y = "Naissances", title = "Naissances enregistrées aux États-Unis")
```




```
slice_max(naissances, n, n = 1)
#> # A tibble: 1 × 2
#>   year      n
#>   <dbl>   <dbl>
#> 1  1957 4200007
```

Le maximum est en **1957**, au cœur du *baby-boom*. Attention : le fichier ne contient que les prénoms donnés au moins 5 fois dans l'année, et les premières années sont mal enregistrées. Ce sont des naissances « enregistrées », pas toutes les naissances.


2. Par année et par sexe

```
bebes |>
  summarise(n = sum(n), .by = c(year, sex)) |>
  ggplot(aes(year, n, fill = sex)) +
  geom_col() +
  facet_grid(sex ~ .) +
  scale_fill_manual(values = c(F = "pink", M = "lightblue")) +
  theme_bw()
```



3. Par décennie

```
bebes |>
  mutate(decennie = year %/% 10 * 10) |>
  summarise(n = sum(n), .by = decennie) |>
  ggplot(aes(factor(decennie), n)) +
  geom_col(fill = "darkblue", width = 0.6) +
  labs(x = "Décennie", y = "Naissances") +
  theme_minimal()
```




`factor(decennie)` donne une barre par décennie avec son étiquette. La dernière décennie (2010) ne contient que 8 années : sa barre est forcément plus basse. Un graphique honnête le signalerait.

4. Le top 10 des garçons en 2017

```
top <- bebes |>
  filter(sex == "M", year == 2017) |>
  slice_max(n, n = 10) |>
  pull(name)
top
#> [1] "Liam"      "Noah"      "William"   "James"     "Logan"     "Benjamin"
#> [7] "Mason"     "Elijah"    "Oliver"    "Jacob"
```

```
bebes |>
  filter(sex == "M", name %in% top) |>
  ggplot(aes(year, n, color = name)) +
  geom_line()
```




`sex == "M"` est nécessaire **deux fois** : certains prénoms (`Logan` , `Elijah` ...) sont aussi donnés à des filles, et leurs courbes se mélangeraient.

5. Les notes en format long

```
notes_long <- notes |>
  pivot_longer(D1:E2, names_to = "Type", values_to = "Note") |>
  mutate(Type = fct_inorder(Type)) |> # ordre des colonnes = ordre du trimestre
  left_join(sexes, by = "ID_etu")


ggplot(notes_long, aes(x = Type, y = Note, fill = Cohorte)) +
  geom_boxplot() +
  facet_wrap(~ Annee) +
  theme_bw()
#> Warning: Removed 1 row containing non-finite outside the scale range
#> (`stat_boxplot()`).
```



Le warning **Removed 1 row** correspond à la note **D2** manquante. Les examens (**E1**, **E2**) ont des notes plus basses et plus dispersées que les devoirs.


6. Par année et par sexe

```
ggplot(notes_long, aes(x = factor(Annee), y = Note, fill = Sex)) +  
  geom_boxplot() +  
  labs(x = "Année", fill = "Sexe")  
#> Warning: Removed 1 row containing non-finite outside the scale range  
#> (`stat_boxplot()`).
```




7. Les positions


```
quatre <- notes_long |> filter(ID_etu %in% paste0("Etu_", 1:4))  
g <- ggplot(quatre, aes(x = ID_etu, y = Note, fill = Type))  
g + geom_col(position = "stack") + ggtitle("stack : la somme (sur 600)")
```



```
g + geom_col(position = "fill") + ggtitle("fill : la part de chaque évaluation (sur 1)")
```



```
g + geom_col(position = "dodge") + ggtitle("dodge : chaque note")
```




Avec `"fill"`, toutes les barres valent 1 : on compare des **parts**, plus des notes. Renommez l'axe y, sinon il annonce encore « Note ».

Et si... ?

1. Sans `color = name`

```
bebes |>
  filter(sex == "M", name %in% top) |>
  ggplot(aes(year, n)) +
  geom_line()
```



`geom_line()` relie **toutes** les lignes du tableau dans l'ordre des x : chaque année, la ligne monte et descend entre les 10 prénoms. Aucun message. `color = name` (ou `group = name`) indique quelles lignes forment **une même courbe**.


2. Sans `summarise()`

```
ggplot(bebes, aes(year, n)) + geom_line()
```

Le graphique (long à afficher : 1.9 million de lignes) est une bande noire : pour chaque année, la ligne parcourt tous les prénoms. `ggplot2` ne résume pas pour vous avec `geom_line()` : la somme se calcule **avant**.

3. `limits` ou `coord_cartesian()`

```
ggplot(notes_long, aes(Type, Note, fill = Cohorte)) +
  geom_boxplot() +
  scale_y_continuous(limits = c(50, 100))
#> Warning: Removed 22 rows containing non-finite outside the scale range
#> (`stat_boxplot()`).
```




```
notes_long |>
  summarise(mediane = median(Note, na.rm = TRUE),
            mediane_sup50 = median(Note[Note >= 50], na.rm = TRUE), .by = Type)
```

```
#> # A tibble: 6 × 3
#>   Type  mediane mediane_sup50
#>   <fct>   <dbl>         <dbl>
#> 1 D1      93.3           93.3
#> 2 D2      90            90
#> 3 E1      75.6           75.6
#> 4 D3     100            100
#> 5 D4      94.1           95
#> 6 E2      82.9           85.4
```

limits retire les 21 notes sous 50 (et le **NA**) **avant** le calcul : la médiane de **E2**, par exemple, passe de 82.86 à 85.39. Le *warning* est le seul indice. `coord_cartesian(ylim = c(50, 100))` zoome sans rien retirer : les boxplots restent justes, et les points sous 50 sortent simplement du cadre.

4. Année numérique

```
ggplot(notes_long, aes(x = Année, y = Note, fill = Sex)) +
  geom_boxplot()
#> Warning: Orientation is not uniquely specified when both the x and y aesthetics are
#> continuous. Picking default orientation 'x'.
#> Warning: Removed 1 row containing non-finite outside the scale range
#> (`stat_boxplot()`).
```




Année est un **nombre** : l'axe x est continu, et **ggplot2** ne sait pas qu'il faut une boîte par année. Il fait une boîte **par sexe**, sur les trois années mélangées, placée vers 2019. Le seul indice est un *warning* qui ne parle pas du problème (**Orientation is not uniquely specified when both the x and y aesthetics are continuous**) : il faut **regarder** l'axe x. `factor(Année)` transforme l'année en **catégorie**.

5. L'ordre oublié

```
notes |>
  pivot_longer(D1:E2, names_to = "Type", values_to = "Note") |>
  ggplot(aes(Type, Note)) +
  geom_boxplot()
```

```
#> Warning: Removed 1 row containing non-finite outside the scale range
#> (`stat_boxplot()`).
```



Sans facteur, **ggplot2** trie le texte **par ordre alphabétique** : D1, D2, D3, D4, E1, E2. Les examens sont regroupés à la fin : un lecteur croirait que les notes baissent en fin de trimestre, alors que c'est le **type** d'évaluation qui compte. **fct_inorder()** (ordre des colonnes) ou **factor(Type, levels = c("D1", "D2", "E1", "D3", "D4", "E2"))** rétablissent l'ordre réel.