

TP1 : R de base et premiers graphiques ggplot2

Avant de débiter

Connectez-vous au serveur RStudio du cours : <https://bif-rstudio.compbio.ulaval.ca>

Ouvrez un **nouveau script** (*File > New File > R Script*) et chargez le *tidyverse*, qui contient **ggplot2** :

```
library(tidyverse)
```

Les données

- **iris** (inclus dans R) : longueur et largeur des sépales et des pétales (cm) de 150 iris de 3 espèces (**Species**) ;
- **diamonds** (inclus dans **ggplot2**) : prix (**price**), poids (**carat**), qualité de la taille (**cut**), couleur et pureté de 53 940 diamants ;
- **/home/public/visu/fruit.tsv** : 16 lignes, une par fruit et par couleur (**FRUIT**, **COULEUR**, **QUANTITE**).

Rappel : les commandes

Objectif	Commande
Graphique de R de base	<code>plot(x, y)</code> , <code>hist(x)</code> , <code>boxplot(y ~ groupe, data = df)</code> , <code>barplot(table(x))</code>
Légende (R de base)	<code>legend("topright", legend = ..., col = ..., pch = ...)</code>
Graphique ggplot2	<code>ggplot(df, aes(x = ..., y = ...)) + geom_...()</code>
Couleur selon une colonne	<code>aes(color = colonne)</code> ; couleur fixe : <code>geom_point(color = "red")</code>
Titre, axes, thème	<code>labs(title = , x = , y =)</code> , <code>theme_bw()</code> , <code>theme(legend.position = "bottom")</code>
Compter les lignes / hauteur donnée	<code>geom_bar()</code> / <code>geom_col()</code>

À votre tour

Avec R de base

1. Tracez le boxplot de `Petal.Length` de `iris`, avec un titre.
2. Tracez l'histogramme de `Sepal.Length` pour l'espèce `versicolor` seulement.
3. Tracez la relation entre la longueur (`Sepal.Length`) et la largeur (`Sepal.Width`) des sépales, une couleur par espèce, avec une **légende juste**.

Avec `ggplot2`

4. Avec `diamonds`, tracez le prix (`price`, en y) selon le poids (`carat`, en x), une couleur selon `cut`. Ajoutez un titre, le thème `theme_bw()`, et placez la légende sous le graphique.
5. Avec `iris`, refaites le graphique de la question 3 avec `ggplot2`, puis ajoutez `geom_smooth(method = "lm", se = FALSE)`. Combien de droites ? Modifiez le code pour obtenir **une seule** droite pour toutes les fleurs, en gardant les points colorés.
6. Importez `fruit.tsv` dans `fruit`. Tracez la quantité de chaque fruit (`geom_col()`), puis le **nombre de fruits** de chaque couleur (`geom_bar()`).
7. Sauvegardez le graphique de la question 4 dans un fichier `diamants.png` de 16 × 10 cm.

Et si... ?

Pour chaque question, **prédisez d'abord la réponse sans exécuter**, puis vérifiez dans R.

1. Et si on écrivait `geom_point(aes(color = "blue"))` à la question 4 ? De quelle couleur seront les points ? Que dira la légende ?
2. Et si on écrivait `geom_point(color = cut)` ?
3. Et si, à la question 3, la légende était `legend = c("virginica", "versicolor", "setosa")` avec `col = 1:3` ? R le signale-t-il ?
4. Et si on écrivait `ggplot(fruit, aes(x = FRUIT, y = QUANTITE)) + geom_bar()` ?
5. À la question 6, quelle est la hauteur de la barre « Citron » ? Pourquoi ? Combien de barres « Rouge » dans le graphique par couleur, et quelle hauteur ?

