

TP2 : construire et ajuster un graphique

Avant de débiter

Ouvrez un **nouveau script** et chargez le *tidyverse*. Les données sont celles du module 6 :

```
library(tidyverse)
bebes <- read_csv("/home/public/tidyverse/babynames.csv")
notes <- read_tsv("/home/public/tidyverse/grades.tsv")
sexes <- read_tsv("/home/public/tidyverse/grades_sex.tsv")
```

Les données

- **babynames.csv** : les prénoms des bébés nés aux États-Unis de 1880 à 2017 : **year**, **sex** (F ou M), **name**, **n** (nombre de bébés), **prop** (proportion des naissances de l'année) ;
- **grades.tsv** : les notes (sur 100) de 79 étudiants du cours : **ID_etu**, six évaluations dans l'ordre du trimestre (**D1**, **D2**, **E1**, **D3**, **D4**, **E2** : devoirs et examens), **Annee**, **Cohorte** ;
- **grades_sex.tsv** : **ID_etu** et **Sex**.

Rappel : les commandes

Objectif	Commande
Résumer avant de tracer	<code>summarise(total = sum(n), .by = c(year, sex))</code>
Une ligne par groupe	<code>aes(color = name)</code> ou <code>aes(group = name)</code>
Positions des barres	<code>geom_col(position = "stack"), "dodge", "fill"</code>
Facettes	<code>facet_wrap(~ var), facet_grid(lignes ~ colonnes)</code>
Couleurs choisies	<code>scale_fill_manual(values = c(F = "pink", M = "lightblue"))</code>

Objectif	Commande
Format long	<code>pivot_longer(D1:E2, names_to = "Type", values_to = "Note")</code>
Ordre des catégories	<code>factor(x, levels = c(...)), fct_inorder(), fct_reorder()</code>
Zoomer	<code>coord_cartesian(ylim = c(...))</code>

À votre tour

Les prénoms

1. Tracez le nombre total de naissances par année (une courbe). En quelle année y a-t-il eu le plus de naissances ?
2. Tracez le nombre de naissances par année **et par sexe** avec des barres, un panneau par sexe (`facet_grid(sex ~ .)`), en rose et bleu clair.
3. Tracez le nombre de naissances **par décennie** avec un barplot (indice : `year %/% 10 * 10`).
4. Trouvez les 10 prénoms de garçons les plus donnés en 2017, puis tracez leur évolution depuis 1880 (une courbe par prénom).

Les notes

5. Passez `notes` en format long (`notes_long` : colonnes `Type` et `Note`), et ajoutez le sexe avec `left_join()`. Tracez les boxplots des notes par type d'évaluation, une couleur par cohorte, un panneau par année. Les évaluations doivent apparaître **dans l'ordre du trimestre**.
6. Tracez les boxplots des notes par année et par sexe.
7. Pour les étudiants `Etu_1` à `Etu_4`, tracez une barre par étudiant, découpée selon le type d'évaluation (`fill = Type`). Comparez les positions `"stack"`, `"fill"` et `"dodge"`. Que représente l'axe y dans chaque cas ?

Et si... ?

Pour chaque question, **prédisez d'abord la réponse sans exécuter**, puis vérifiez dans R.

1. Et si, à la question 4, on retirait `color = name` ? À quoi ressemblera la courbe ?
2. Et si on traçait la question 1 **sans** `summarise()` : `ggplot(bebes, aes(year, n)) + geom_line()` ?
3. Et si on ajoutait `scale_y_continuous(limits = c(50, 100))` à la question 5 ? Les boxplots changent-ils ? Comparez avec `coord_cartesian(ylim = c(50, 100))`.
4. Et si, à la question 6, on écrivait `aes(x = Annee, ...)` au lieu de `aes(x = factor(Annee), ...)` ?
5. Et si on oubliait l'ordre des évaluations à la question 5 : dans quel ordre seraient-elles ? Qu'est-ce qui deviendrait trompeur ?

