

Exercice formatif : statistiques avec R

Répondez **sans exécuter de code**. Le but est de vérifier ce que vous avez compris, pas d'avoir tout juste : on corrige ensemble juste après.

1. Lire un t-test

On compare l'expression d'un gène (unités arbitraires) entre 8 souris *knock-out* (K0) et 8 souris sauvages (WT) :

```
Welch Two Sample t-test

data: expression by genotype
t = -2.61, df = 13.2, p-value = 0.021
alternative hypothesis: true difference in means between group K0 and group WT is not equal to 0
95 percent confidence interval:
 -3.91 -0.37
sample estimates:
mean in group K0 mean in group WT
           6.02           8.16
```

(a) Le gène est-il plus ou moins exprimé chez les KO ? De combien ? (b) Que signifie l'intervalle de confiance ? (c) Écrivez une phrase de conclusion.

2. Vérifier la normalité

Avec 6 valeurs par groupe, une étudiante obtient `shapiro.test()` : $p = 0.31$ et $p = 0.58$. Elle écrit : « les données sont normales, donc j'utilise un t-test ». Qu'en pensez-vous ?

3. Apparié ou non ?

On mesure la pression artérielle de 15 patients avant et après un traitement. Une analyse donne $p = 0.12$ avec `t.test(pression ~ moment, data = df)`. (a) Quel est le problème ? (b) Que faut-il faire ? (c) Le résultat peut-il changer beaucoup ?

4. Une ANOVA suspecte

Trois lignées cellulaires sont codées 1, 2 et 3 dans une colonne numérique `lignee`. On obtient :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
<code>lignee</code>	1	2.03	2.028	0.325	0.575
Residuals	22	137.43	6.247		

(a) Qu'est-ce qui cloche ? (b) Combien devrait valoir Df ? (c) Comment corriger ?

5. Tests multiples

On teste 20 000 gènes, au seuil de 5 %, dans une expérience où **aucun** gène ne change réellement. (a) Combien de gènes « significatifs » attendez-vous ? (b) Que fait la correction de Benjamini-Hochberg ? (c) Quelle colonne de DESeq2 faut-il utiliser ?

6. Lire une régression

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5780.831	305.815	-18.903	0
<code>flipper_len</code>	49.686	1.518	32.722	0

Ce modèle explique la masse des manchots (g) par la longueur de leur nageoire (mm), sur des nageoires de 172 à 231 mm ; $R^2 = 0.76$. (a) Interprétez la pente. (b) Que vaut le R^2 en mots ? (c) Peut-on prédire la masse d'un manchot dont la nageoire mesure 300 mm ?

7. Lire un résultat DESeq2

```
log2 fold change (MLE): dex untrt vs trt
      gene baseMean log2FoldChange      padj
ENSG000000109906    385.1         -7.35 2.3e-40
ENSG000000162692    508.2          3.69 5.4e-81
ENSG00000005513      4.4          1.29      NA
```

-
- (a) Les deux premiers gènes sont-ils induits ou réprimés par la dexaméthasone (trt) ? (b) Que signifie le NA du troisième ? (c) Qu'aurait-il fallu faire avant `DESeq()` pour éviter la confusion ?