Exercice formatif : statistiques avec R

Répondez **sans exécuter de code**. Le but est de vérifier ce que vous avez compris, pas d'avoir tout juste : on corrige ensemble juste après.

1. Lire un t-test

On compare l'expression d'un gène (unités arbitraires) entre 8 souris *knock-out* (`KO`) et 8 souris sauvages (`WT`) :

```
    Welch Two Sample t-test

data:  expression by genotype
t = -2.61, df = 13.2, p-value = 0.021
alternative hypothesis: true difference in means between group KO and group WT is not equal
to 0
95 percent confidence interval:
 -3.91 -0.37
sample estimates:
mean in group KO mean in group WT
            6.02             8.16
```

(a) Le gène est-il plus ou moins exprimé chez les KO ? De combien ? (b) Que signifie l'intervalle de confiance ? (c) Écrivez une phrase de conclusion.

2. Vérifier la normalité

Avec 6 valeurs par groupe, une étudiante obtient `shapiro.test()` : p = 0.31 et p = 0.58. Elle écrit : « les données sont normales, donc j'utilise un t-test ». Qu'en pensez-vous ?

3. Apparié ou non ?

On mesure la pression artérielle de 15 patients avant et après un traitement. Une analyse donne p = 0.12 avec `t.test(pression ~ moment, data = df)`. (a) Quel est le problème ? (b) Que faut-il faire ? (c) Le résultat peut-il changer beaucoup ?

4. Une ANOVA suspecte

Trois lignées cellulaires sont codées `1`, `2` et `3` dans une colonne numérique `lignee`. On obtient :

```
            Df Sum Sq Mean Sq F value Pr(>F)
lignee       1   2.03   2.028   0.325  0.575
Residuals   22 137.43   6.247
```

(a) Qu'est-ce qui cloche ? (b) Combien devrait valoir `Df` ? (c) Comment corriger ?

5. Tests multiples

On teste 20 000 gènes, au seuil de 5 %, dans une expérience où **aucun** gène ne change réellement. (a) Combien de gènes « significatifs » attendez-vous ? (b) Que fait la correction de Benjamini-Hochberg ? (c) Quelle colonne de DESeq2 faut-il utiliser ?

6. Lire une régression

```
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -5780.831    305.815 -18.903        0
flipper_len    49.686      1.518  32.722        0
```

Ce modèle explique la masse des manchots (g) par la longueur de leur nageoire (mm), sur des nageoires de 172 à 231 mm ; $R^2 = 0.76$. (a) Interprétez la pente. (b) Que vaut le R^2 en mots ? (c) Peut-on prédire la masse d'un manchot dont la nageoire mesure 300 mm ?

7. Lire un résultat DESeq2

```
log2 fold change (MLE): dex untrt vs trt
            gene baseMean log2FoldChange    padj
 ENSG00000109906    385.1          -7.35 2.3e-40
 ENSG00000162692    508.2           3.69 5.4e-81
 ENSG00000005513      4.4           1.29      NA
```

(a) Les deux premiers gènes sont-ils induits ou réprimés par la dexaméthasone (`trt`) ? (b) Que signifie le `NA` du troisième ? (c) Qu'aurait-il fallu faire avant `DESeq()` pour éviter la confusion ?