

Exercice formatif : statistiques avec R — corrigé

Chaque réponse est suivie de la notion à revoir si elle a été manquée.

1. Lire un t-test

On compare l'expression d'un gène (unités arbitraires) entre 8 souris *knock-out* (K0) et 8 souris sauvages (WT) :

```
Welch Two Sample t-test

data: expression by genotype
t = -2.61, df = 13.2, p-value = 0.021
alternative hypothesis: true difference in means between group K0 and group WT is not equal to 0
95 percent confidence interval:
 -3.91 -0.37
sample estimates:
mean in group K0 mean in group WT
        6.02         8.16
```

- (a) Le gène est-il plus ou moins exprimé chez les KO ? De combien ? (b) Que signifie l'intervalle de confiance ? (c) Écrivez une phrase de conclusion.
- (a) **Moins** exprimé : la différence est KO – WT (ordre alphabétique des niveaux) = 6.02 – 8.16 = –2.14.
 (b) La vraie différence de moyennes est, avec 95 % de confiance, entre –3.91 et –0.37 : l'effet pourrait être modeste ou assez fort, mais il est négatif. (c) *Chez les souris KO, l'expression est inférieure de 2.1 unités en moyenne (IC 95 % : 0.4 à 3.9 ; t-test de Welch, p = 0.021). À revoir : lire la sortie de t.test(), l'intervalle de confiance.*

2. Vérifier la normalité

Avec 6 valeurs par groupe, une étudiante obtient `shapiro.test()` : p = 0.31 et p = 0.58. Elle écrit : « les données sont normales, donc j'utilise un t-test ». Qu'en pensez-vous ?

p > 0.05 signifie qu'on **ne rejette pas** la normalité, pas qu'on l'a démontrée. Avec 6 valeurs, le test n'a presque aucune puissance : même des données nettement asymétriques donnent souvent p > 0.05. Il faut regarder les points (Q-Q plot, valeurs aberrantes) et, en cas de doute, utiliser un test de Wilcoxon. À revoir : ce que *Shapiro-Wilk* ne dit pas.

3. Apparié ou non ?

On mesure la pression artérielle de 15 patients avant et après un traitement. Une analyse donne p = 0.12 avec `t.test(pression ~ moment, data = df)`. (a) Quel est le problème ? (b) Que faut-il faire ? (c) Le résultat peut-il changer beaucoup ?

- (a) Ce sont les **mêmes patients** : les mesures sont **appariées**, alors que la formule fait un test pour groupes indépendants. (b) Passer en format large (`pivot_wider()`, une ligne par patient) puis

`t.test(apres, avant, paired = TRUE)`. (c) Oui : le test apparié retire la variabilité entre patients. Avec sleep, p passait de 0.08 à 0.003. *À revoir : indépendants ou appariés.*

4. Une ANOVA suspecte

Trois lignées cellulaires sont codées 1, 2 et 3 dans une colonne numérique `lignee`. On obtient :

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
lignee	1	2.03	2.028	0.325	0.575
Residuals	22	137.43	6.247		

(a) Qu'est-ce qui cloche ? (b) Combien devrait valoir Df ? (c) Comment corriger ?

(a) Df = 1 : `aov()` a traité `lignee` comme un **nombre** et ajusté une droite, au lieu de comparer trois groupes. (b) 3 groupes – 1 = **2**. (c) `aov(y ~ factor(lignee), data = df)`. Aucun message ne signale l'erreur ; sur l'exemple des diapos (doses codées 1, 2, 3), la version facteur donnait $p < 0.001$ au lieu de 0.57. *À revoir : un groupe codé en nombre.*

5. Tests multiples

On teste 20 000 gènes, au seuil de 5 %, dans une expérience où **aucun** gène ne change réellement. (a) Combien de gènes « significatifs » attendez-vous ? (b) Que fait la correction de Benjamini-Hochberg ? (c) Quelle colonne de DESeq2 faut-il utiliser ?

(a) Environ $20\,000 \times 0.05 = 1000$, tous faux positifs. (b) Elle ajuste les p-values pour contrôler le **FDR** : parmi les gènes retenus avec $\text{padj} < 0.05$, on accepte qu'environ 5 % soient de faux positifs ; ici, elle n'en retiendrait (presque) aucun. (c) `padj`, jamais `pvalue`. *À revoir : tests multiples.*

6. Lire une régression

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5780.831	305.815	-18.903	0
flipper_len	49.686	1.518	32.722	0

Ce modèle explique la masse des manchots (g) par la longueur de leur nageoire (mm), sur des nageoires de 172 à 231 mm ; $R^2 = 0.76$. (a) Interprétez la pente. (b) Que vaut le R^2 en mots ? (c) Peut-on prédire la masse d'un manchot dont la nageoire mesure 300 mm ?

(a) Chaque millimètre de nageoire en plus correspond à **49.7 g** de masse en plus, en moyenne. (b) La longueur de la nageoire explique 76 % de la variance de la masse. (c) Non : 300 mm est **hors de l'étendue des données**. R prédirait environ 9 kg sans avertissement, mais rien ne garantit que la relation reste linéaire. *À revoir : lire `lm()`, ne pas extrapoler.*

7. Lire un résultat DESeq2

log2 fold change (MLE): dex untrt vs trt	
gene	baseMean log2FoldChange padj

ENSG00000109906	385.1	-7.35	2.3e-40
ENSG00000162692	508.2	3.69	5.4e-81
ENSG00000005513	4.4	1.29	NA

- (a) Les deux premiers gènes sont-ils induits ou réprimés par la dexaméthasone (trt) ? (b) Que signifie le NA du troisième ? (c) Qu'aurait-il fallu faire avant `DESeq()` pour éviter la confusion ?
- (a) L'en-tête dit `untrt vs trt` : le non-traité **par rapport au** traité. Le premier gène (-7.35) est donc **induit** par la dexaméthasone (environ $2^{7.4} \approx 163$ fois) ; le deuxième (+3.69) est **réprimé**. (b) Le troisième **n'a pas été testé** (trop faiblement exprimé ou valeur aberrante) : on ne peut rien conclure, ce n'est pas un « non DE ». (c) Fixer le niveau de référence : `factor(dex, levels = c("untrt", "trt"))`.
À revoir : le niveau de référence, lire l'en-tête des résultats.