

TP1 : décrire, vérifier, comparer deux groupes

Avant de débiter

Connectez-vous au serveur RStudio du cours : <https://bif-rstudio.compbio.ulaval.ca>

Ouvrez un **nouveau script** (*File > New File > R Script*) et chargez les packages :

```
library(tidyverse)
library(car)          # pour leveneTest()
```

Si R répond `there is no package called 'car'` : `install.packages("car")` (une seule fois).

Les données

Le fichier `/home/public/stat/penguins.tsv` décrit 344 manchots de l'archipel Palmer (Antarctique), mesurés de 2007 à 2009 :

Colonne	Contenu
<code>species</code>	espèce : <code>Adelie</code> , <code>Chinstrap</code> ou <code>Gentoo</code>
<code>island</code>	île : <code>Biscoe</code> , <code>Dream</code> ou <code>Torgersen</code>
<code>bill_len</code> , <code>bill_dep</code>	longueur et profondeur du bec (mm)
<code>flipper_len</code>	longueur de la nageoire (mm)
<code>body_mass</code>	masse (g)
<code>sex</code>	<code>female</code> ou <code>male</code>
<code>year</code>	année de la mesure

Vous utiliserez aussi `sleep`, un jeu de données inclus dans R : le sommeil gagné (`extra`, en heures) par 10 patients (`ID`) avec deux doses d'un somnifère (`group`). **Chaque patient a reçu les deux doses.**

Rappel : les commandes

Objectif	Commande
Résumer par groupe	<code>summarise(..., .by = groupe)</code>
Q-Q plot	<code>ggplot(df, aes(sample = y)) + stat_qq() + stat_qq_line()</code>
Normalité	<code>shapiro.test(x)</code>
Égalité des variances	<code>car::leveneTest(y ~ factor(groupe), data = df)</code>
Deux groupes indépendants	<code>t.test(y ~ groupe, data = df), wilcox.test(y ~ groupe, data = df)</code>
Deux mesures appariées	<code>t.test(apres, avant, paired = TRUE)</code>

À votre tour

0. Importez le fichier dans une variable `manchots`. Combien de manchots ? Combien n'ont pas de sexe connu ?
1. Pour chaque espèce **et** chaque sexe, calculez l'effectif, la moyenne, la médiane et l'écart-type de `body_mass`.
2. Créez `adelie` : les manchots Adélie dont le sexe est connu. Tracez l'histogramme et le Q-Q plot de `body_mass`, un panneau par sexe (`facet_wrap(~ sex)`). La normalité est-elle plausible ?
3. Faites le test de Shapiro-Wilk pour chaque sexe, puis le test de Levene. Que concluez-vous ?
4. Comparez la masse des mâles et des femelles Adélie avec `t.test()`. Écrivez une phrase de conclusion qui donne **la différence**, son **intervalle de confiance** et la p-value.
5. Refaites la comparaison avec `wilcox.test()`. La conclusion change-t-elle ?
6. Avec `sleep` : tracez un point par patient et par dose, reliés par patient (`geom_line(aes(group = ID))`). Faites le test **indépendant**, puis le test **apparié** (passez d'abord en format large avec `pivot_wider()`). Pourquoi les p-values sont-elles si différentes ? Lequel est juste ?

Et si... ?

Pour chaque question, **prédisez d'abord la réponse sans exécuter**, puis vérifiez dans R.

1. Et si on oubliait de retirer les manchots de sexe inconnu : `t.test(body_mass ~ sex, data = filter(manchots, species == "Adelie"))`. Le résultat change-t-il ? Combien de manchots le test utilise-t-il, et R le dit-il ?
2. Et si on voulait comparer les trois espèces avec `t.test(body_mass ~ species, data = manchots)` ? Lisez le message.
3. Comparez la masse des Adélie et des Chinstrap. Peut-on conclure que les deux espèces ont **la même** masse ? Que dit l'intervalle de confiance ?
4. Et si on changeait l'ordre des niveaux, `mutate(sex = factor(sex, levels = c("male", "female")))`, avant le t-test de la question 4 : qu'est-ce qui change dans la sortie ? Qu'est-ce qui ne change pas ?

5. Et si, dans le test apparié de `sleep`, les valeurs de la dose 2 étaient dans le désordre
(`sample(sommeil$dose_2)`) : R signale-t-il un problème ? Que devient la p-value ?

