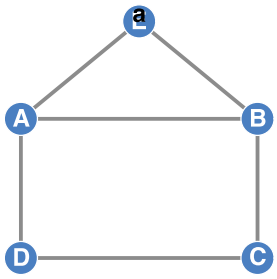
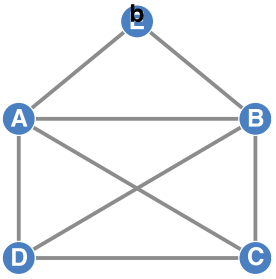
Exercice formatif : introduction aux réseaux en biologie

Répondez **sans exécuter de code**. Le but est de vérifier ce que vous avez compris, pas d'avoir tout juste : on corrige ensemble juste après.

1. Sans lever le crayon





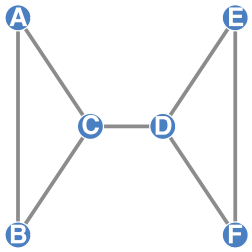
(a) et (b) : peut-on parcourir chaque lien une seule fois, sans lever le crayon ? Si oui, d'où faut-il partir ? Justifiez sans tracer. (c) Un réseau de régulation (un facteur de transcription → ses gènes cibles) est-il dirigé ? Peut-il contenir des boucles ? Que signifierait une boucle ?

2. Construire et lire un graphe

```
aretes <- tibble(from  = c("P1", "P1", "P2", "P3"),
                 to    = c("P2", "P3", "P3", "P4"),
                 score = c(0.9, 0.4, 0.7, 0.95))
proteines <- tibble(name = c("P1", "P2", "P3", "P4", "P5"))
g1 <- graph_from_data_frame(aretes)
g2 <- graph_from_data_frame(aretes, directed = FALSE, vertices = proteines)
```

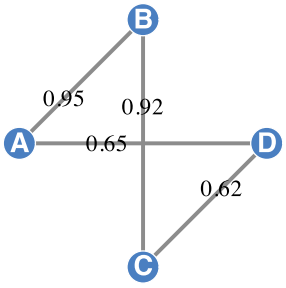
(a) Que contient la première ligne de `g1` (lettres et nombres) ? Pourquoi pas de `W` ? (b) Et celle de `g2` ? (c) Écrivez la matrice d'adjacence de `g2`. (d) Déduisez-en le degré de chaque protéine et la densité de `g2`.

3. Calculer à la main



Calculez (a) le degré de chaque nœud et la densité ; (b) la distance de A à F et le diamètre ; (c) le *clustering* local de A et de C ; (d) quels nœuds ont la plus forte intermédiarité, et pourquoi ?

4. Des poids qui trompent



Dans ce petit réseau de co-expression, l'attribut `weight` est la corrélation entre deux gènes. (a) Quel chemin de A à C `shortest_paths(w, "A", "C")` renvoie-t-il ? Calculez sa longueur. (b) Quel gène a la plus forte intermédiarité selon `betweenness(w)` ? Et sans les poids ? (c) Proposez deux corrections.

5. Un réseau de co-expression

```
#>        DUSP1 ZBTB16 KCTD12 DDX3Y
#> DUSP1   1.00   0.98  -1.00 -0.04
#> ZBTB16  0.98   1.00  -0.98 -0.14
#> KCTD12 -1.00  -0.98   1.00  0.01
#> DDX3Y  -0.04  -0.14   0.01  1.00
```

Corrélations de Pearson entre quatre gènes d'`airway` (8 échantillons) : *DUSP1* et *ZBTB16* sont induits par la dexaméthasone, *KCTD12* est réprimé, *DDX3Y* est sur le chromosome Y. (a) Quels liens avec le seuil r > 0.8 ? Quels gènes sont isolés ? (b) Et avec `abs(r) > 0.8` ? Qu'est-ce que cela change pour l'interprétation ? (c) Pourquoi faut-il se méfier d'une corrélation calculée sur 8 échantillons ? (d) Un lien *DUSP1–ZBTB16* veut-il dire que l'un régule l'autre ?

6. Interpréter des modules

On applique `cluster_louvain()` (avec `set.seed(1)`) au réseau de co-expression des 150 gènes d'`airway` (r > 0.8), puis on compte les gènes de chaque module selon leur statut et leur chromosome (Y ou autre) :

```
#>
#> module induit réprimé non DE, autre non DE, chr. Y
#>      1      0       0             2              7
#>      2      0      17             1              0
#>      3      6       4            26              0
#>      4     45       0             0              0
#>      5     26       0             3              0
#>      6      1       3             6              0
#>      7      0       1             0              0
#>      8      0       0             1              0
#>      9      0       0             1              0
```

(a) Que montrent les modules induits et réprimés ? (b) Interprétez le module 1. Comment le vérifier ? (c) Une camarade relance le calcul avec une autre graine : son module 1 contient des gènes induits. A-t-elle fait une erreur ?

7. Vérifier une analyse

Un étudiant analyse un réseau d'interactions protéiques téléchargé de STRING :

```
ppi <- read_tsv("interactions.tsv")   # prot1, prot2, weight = score STRING (0 à 1)
g <- graph_from_data_frame(ppi)
diameter(g)                           # « le signal traverse la cellule en ... étapes »
modules <- cluster_louvain(g)
```

(a) R s'arrête à la dernière ligne avec `Multi-level community detection works for undirected graphs only`. Pourquoi ? (b) Deux autres problèmes, que R ne signale pas. (c) Après correction, il écrit : « *TP53* est le plus grand hub du réseau, c'est donc la protéine la plus importante ». Une objection.