Exercice formatif : bases de données et analyses fonctionnelles

Répondez **sans exécuter de code**. Le but est de vérifier ce que vous avez compris, pas d'avoir tout juste : on corrige ensemble juste après.

1. Où chercher, et que vaut l'information ?

Pour chaque ressource, dites si la base est primaire ou secondaire, et si l'information a été vérifiée par un expert : (a) les lectures FASTQ d'une expérience dans SRA ; (b) une entrée TrEMBL ; (c) l'entrée Swiss-Prot `P38398` ; (d) une voie métabolique de Reactome.

2. Gene Ontology

Un gène est annoté au terme *cellular response to glucocorticoid stimulus*, dont un ancêtre est *response to steroid hormone*. (a) Dans quelle branche de GO sont ces termes ? (b) Ce gène compte-t-il dans l'ensemble de gènes de *response to steroid hormone* ? Pourquoi ? (c) Son annotation porte le code `IEA` : qu'est-ce que cela signifie ?

3. Prédire une conversion

```
ids <- c("ENSG00000096060", "ENSG00000004866", "ENSG00000120129.6")
conv <- AnnotationDbi::select(org.Hs.eg.db, keys = ids, keytype = "ENSEMBL", columns
= "SYMBOL")
```

`ENSG00000004866` correspond à deux gènes, *ST7* et *ST7-OT3*. (a) Combien de lignes dans `conv` ? (b) Combien de `NA`, et pourquoi ? (c) Que renverrait `mapIds()` avec les mêmes arguments (`column = "SYMBOL"`) ?

4. L'urne

Sur 18 000 gènes testés, 500 sont induits. Un terme GO contient 90 gènes de l'univers, dont 10 sont induits. (a) Combien de gènes induits attendait-on dans ce terme par hasard ? (b) Quel test permet de juger si 10 est « beaucoup » ? (c) Pourquoi ne pas conclure avec la p-value brute ?

5. Une ORA à vérifier

Un collègue envoie ses 900 gènes DE (induits et réprimés ensemble) à un site web d'enrichissement, sans préciser d'univers. Il obtient *extracellular matrix organization* avec p = 0.003 et conclut : « le traitement active l'organisation de la matrice extracellulaire ». Relevez trois problèmes.

6. Lire une GSEA

Une GSEA sur des résultats DESeq2 (en-tête : `dex trt vs untrt`), avec les gènes classés par `stat`, donne pour *response to glucocorticoid* : NES = 1.83, p.adjust = 0.009. (a) Les gènes de cet ensemble sont-ils plutôt plus ou moins exprimés sous traitement ? (b) Une collègue obtient NES = −1.83 sur les mêmes données. Donnez une explication. (c) Pourquoi la GSEA peut-elle détecter cet ensemble même si peu de ses gènes passent le seuil `padj` < 0.05 ?